¿En qué medida las variables fisiológicas registradas permiten clasificar con precisión el nivel de riesgo de una gestante, y cuáles de estos factores tienen mayor peso predictivo?

Integrantes:

Sara Gabriela Chisaba Cárdenas
Alejandra Cortes Murillo
Juan Esteban Silva Arévalo

Curso:
Estadística Bayesiana

Universidad Externado de Colombia
Año 2026

1. Planteamiento del problema

1.1. Contexto

La reducción de la mortalidad materna y fetal, junto con tratamientos oportunos durante el embarazo son factores prioritarios a nivel de sanidad pública global lo cual se alinea con los ODS, como se menciona en (Organization, s.f.) "Meta 3.1 de los ODS: Reducir la tasa mundial de mortalidad materna a menos de 70 por cada 100 000 nacidos vivos... Un poco más del 90 % de todas las muertes maternas ocurren en países de ingresos y medios bajos en 2023". Por eso el principal problema radica en situaciones de monitorización primaria en zonas rurales o vulnerables de un país en desarrollo junto con la identificación temprana de los síntomas y/o complicaciones para descubrir el nivel de riesgo en función del seguimiento continuo de signos vitales como la frecuencia cardíaca, presión arterial sistólica, temperatura corporal, etc. Sin embargo, evaluaciones puntuales o un control inconsistente dificultan la detección a tiempo de condiciones médicas críticas como la preeclampsia, diabetes gestacional, anemia ferropénica o hipertensión arterial, y según (Organization, s.f.) "La mayoría de las muertes maternas son prevenibles, ya que existen soluciones sanitarias bien conocidas para prevenir o controlar las complicaciones."

No obstante, se depende demasiado del presupuesto público y gubernamental para el financiamiento de proyectos de tecnologías o nuevas infraestructuras en la salud pública, como lo menciona (Ramos Vázquez, 2019) "La mayoría de muertes, lesiones y problemas de salud se pueden evitar mejorando el acceso a servicios adecuados de atención de la salud, incluidos los métodos de planificación familiar eficaces y la atención obstétrica de emergencia, reconociendo el derecho de la mujer y del hombre a la información y al acceso a métodos seguros, eficaces y asequibles...". Bajo esta perspectiva y considerando que las complicaciones no detectadas a tiempo generan hospitalizaciones obstétricas, representando un costo significativamente mayor para el sistema de salud y las familias.

Asimismo, existen grandes diferencias respecto a la atención médica prenatal offeredida o disponible en los distintos centros de atención rurales, alejados de las ciudades donde hay una brecha sea tecnológica o económica que dificulta el debido proceso de monitorización durante el embarazo. Por otro lado, el difícil acceso a recursos, bienes y servicios como lo es el agua potable y el sistema de saneamiento básico en ciertas comunidades vulnerables puede incrementar la susceptibilidad a infecciones durante la gestación y en consecuencia enfermedades.

Dicho esto y en síntesis de lo anterior, el cumplimiento estricto de las regulaciones sobre privacidad y confidencialidad de la información médica de los pacientes es fundamental, al igual que las exigencias reglamentarias para la validación y certificación de modelos de Inteligencia Artificial y/o Estadística aplicados a la salud humana. Dado el tipo de datos a tratar, en este caso, se trata de información recopilada de diferentes hospitales, centros médicos de salud materna y clínicas comunitarias en zonas rurales de Bangladesh mediante un sistema de monitoreo de riesgos basado en IoT, con 1014 registros de pacientes con variaciones simultáneas en distintos indicadores fisiológicos, lo que demanda procesos de identificación de factores de riesgo para la adecuada intervención médica.

1.1.1. Fenómeno

En el proceso de parto, algunas mujeres sufren graves consecuencias, llegando incluso a la muerte. En algunos casos, se detectan en los últimos meses de embarazo enfermedades que podrían poner en riesgo a la madre gestante o al bebé.

- Síntomas
- Abortos espontáneos.
- Madres gestantes con hipertensión.
- Pareja de la madre gestante teniendo que decidir entre la vida de ella y su bebé.
- Partos complicados o sin éxito.
- Desigualdad social entre la zona urbana y la rural, en cuanto a la natalidad. Cerca del 43 % vive en zonas urbanas, impulsada por el crecimiento de su capital, Daca.
- Madres o bebés en UCI después del parto.
- Afectaciones psicológicas de las madres posterior al parto.
- Bajas tasas de natalidad. En 1990 la tasa era de 32.8 y para 2022 la misma tasa fue de 19.8.

1.1.2. Problema

No se ha profundizado lo suficiente en la evaluación de la suficiencia de los datos clínicos de rutina para la detección oportuna de riesgos durante el embarazo en entornos con recursos limitados. Aunque la literatura indica que el seguimiento de signos vitales en la atención primaria posee un valor predictivo fundamental respecto a datos meramente demográficos, la necesidad de determinar qué tan viable y preciso resulta implementar estos modelos predictivos cuando se trabaja bajo la restricción de muestras pequeñas y la escasez de personal u equipo médico aún se evidencia.

2. Pregunta de investigación

¿En qué medida las variables fisiológicas registradas (presión arterial, glucosa, temperatura corporal, frecuencia cardíaca y edad) permiten clasificar con precisión el nivel de riesgo (RiskLevel) de una gestante, y cuáles de estos factores tienen mayor peso predictivo?

3. Justificación

1. Resultados esperados y riesgos proyectados:

El proyecto nos ofrecerá un sistema predictivo de triaje prenatal adaptado a entornos de atención primaria en comunidades rurales de escasos recursos. Con una de las bases, las sugerencias de optimización de hiperparámetros y selección de modelos (Nogholi et al., 2026), se espera construir un modelo computacionalmente eficaz y de alto rendimiento que priorice la sensibilidad o recall, garantizando la detección oportuna de gestantes en estado crítico antes del parto. Este resultado permitirá aclarar la toma de decisiones clínicas y optimizar la asignación de recursos públicos en zonas rurales, orientando el transporte médico como ambulancias y la remisión a centros hospitalarios únicamente a los casos que representan un verdadero alto riesgo y no una falsa alarma (Nogholi et al., 2026).

Por otro lado, los principales riesgos del proyecto serían el sobreajuste o la pérdida de precisión al transferir el modelo a otras regiones desatendidas y/o contextos (Nogholi et al., 2026), la presencia de ruido o fallas en la captura de características fisiológicas de las madres gestantes mediante sensores IoT, y al ser modelos opacos (dan el resultado pero no una explicación médica al respecto), se genera una falta de interpretación clínica y desconfianza del personal médico. Al no integrar mecanismos de Inteligencia Artificial Explicable (XAI), existe el peligro de que la herramienta sea ignorada en la práctica real o rechazada (Nogholi et al., 2026).

3.1. Mapa de Actores

El desarrollo de un modelo predictivo de riesgo materno-perinatal trasciende la precisión técnica; su éxito depende de equilibrar las exigencias clínicas, regulatorias y operativas de todo el mapa de actores.

1. **Decisores:**
   - Directores médicos.
   - Jefes de obstetricia.
   - Instituciones prestadoras de servicios de salud (directores financieros y de protección de datos).
   - Comités de ética.
2. **Usuarios:**
   - Médicos generales.
   - Ginecobstetras.
   - Enfermeros.
3. **Afectados:**
   - Madres gestantes.
   - Bebés.
   - Familiares.
   - Médicos.
4. **Responsables:**
   - Encargados del proyecto.
   - Equipo de Ciencia de Datos.
   - Capacitadores.

Además de estos en específico, las mujeres se desempeñan en varios ámbitos, por lo que situaciones que las pongan en riesgo influyen también en sus empleadores, en sus círculos sociales, personas de su entorno laboral, colectivos sociales, entre otros.

4. Objetivos

Desarrollar un modelo de clasificación que, a partir de las variables fisiológicas registradas (presión arterial sistólica y diastólica, glucosa, temperatura corporal, frecuencia cardíaca y edad), permita predecir con precisión el nivel de riesgo (RiskLevel) de una gestante, identificando los factores con mayor peso predictivo para facilitar la intervención médica oportuna.

4.1. Objetivos específicos

1. Describir el comportamiento y distribución de las variables fisiológicas según el nivel de riesgo.
2. Identificar los factores fisiológicos más asociados con un riesgo alto.
3. Construir y comparar modelos que permitan clasificar el nivel de riesgo con mayor precisión.
4. Proponer criterios para priorizar la atención médica según el nivel de riesgo detectado.

5. Análisis Exploratorio

Se parte de una base de datos recolectada a partir de un sistema de sensores IoT para desarrollar un mecanismo de monitoreo efectivo y de predicción del nivel de riesgo que puede tener una madre gestante en el contexto de zonas rurales o vulnerables de un país en desarrollo (Bangladesh), con el fin de reducir la tasa de mortalidad materna e infantil. La base de datos cuenta con 6 variables predictoras continuas y 1014 registros de madres gestantes, pacientes de diferentes hospitales, clínicas comunitarias y centros de atención materna en zonas rurales de Bangladesh.

5.1. Análisis Descriptivo

La base de datos cuenta con 6 variables y 1014 registros de madres gestantes. Se procedió a evaluar el comportamiento individual de las variables fisiológicas de las 1014 gestantes mediante un análisis estadístico descriptivo.

Con la información observada en la información estadística del dataset, se concluye:

Cuadro 1: Estadísticas descriptivas de las variables fisiológicas del dataset ($N = 1014$)

	Age	SystolicBP	DiastolicBP	BS	BodyTemp	HeartRate
count	1014.00	1014.00	1014.00	1014.00	1014.00	1014.00
mean	29.87	113.20	76.46	8.73	98.67	74.30
std	13.47	18.40	13.89	3.29	1.37	8.09
min	10.00	70.00	49.00	6.00	98.00	7.00
25 %	19.00	100.00	65.00	6.90	98.00	70.00
50 %	26.00	120.00	80.00	7.50	98.00	76.00
75 %	39.00	120.00	90.00	8.00	98.00	80.00
max	70.00	160.00	100.00	19.00	103.00	90.00

1. El valor mínimo de la frecuencia cardíaca es de 7.0 latidos por minuto, lo cual es biológicamente imposible. Esto demuestra que existen evidencias de fallos al momento de registrar en el sistema estos resultados (artefacto de sensor), registrando un valor cercano a cero en vez de un nulo oficial. Por lo que se toma acción para evitar errores en el entrenamiento del algoritmo futuro.
2. Respecto a lo reflejado en la glucosa de la sangre (BS): La media respecto al rango normal está elevada; sin embargo, se observa un paciente con 19 mmol/L de glucosa en sangre, lo que puede indicar una hiperglucemia severa. Al compararlo con el 75 % de los datos que están por debajo de 8.0 mmol/L, ese valor máximo confirma que la distribución tiene un sesgo positivo hacia la derecha, causado por pacientes con riesgo crítico.
3. Presión Arterial, diastólica y sistólica: La presión sistólica varía desde un mínimo de 70 hasta un máximo de 160 mmHg, y la diastólica llega hasta 100 mmHg. Teniendo en cuenta el contexto de la salud materna, una presión de 160/100 mmHg es una alarma inmediata que usualmente indica preeclampsia o hipertensión gestacional severa. De igual manera, la desviación estándar de la sistólica es de 18.4, lo que muestra una dispersión muy alta de los datos, sugiriendo que las pacientes están repartidas entre rangos muy saludables y rangos de emergencia médica.
4. Temperatura Corporal: La desviación estándar es extremadamente baja, de solo 1.37. El 25 %, el 50 % y el 75 % de los datos valen exactamente lo mismo: 98.0 °F (aprox. 36.6 °C), lo que se debe a la configuración del termómetro digital utilizado en el sistema IoT, el cual presenta baja sensibilidad o redondea los datos. Casi toda la muestra de 1014 mujeres está estancada exactamente en 98 °F, y solo unas pocas llegaron al máximo de 103 °F, aportando poca variabilidad al modelo.
5. Edad: Respecto a esta variable, aunque el

75 % de las mujeres tienen 39 años o menos (edad fértil), tener un registro de una paciente de 10 años y otra de 70 años en un estudio de salud materna representa casos atípicos extremos (embarazo infantil, geriatría extrema o errores de digitalización hospitalaria).

Cuadro 2: Estructura de las variables y verificación de valores nulos ($N = 1014$)

Variable	Tipo de Dato	Registros No Nulos	Valores Nulos (NaN)
Age	Entero (`int64`)	1014	0
SystolicBP	Entero (`int64`)	1014	0
DiastolicBP	Entero (`int64`)	1014	0
BS	Flotante (`float64`)	1014	0
BodyTemp	Flotante (`float64`)	1014	0
HeartRate	Entero (`int64`)	1014	0
RiskLevel	Objeto (`object`)	1014	0

No se observan datos nulos tradicionales en ninguna variable. Al ser una base recolectada mediante sensores IoT, estos están diseñados para reducir o eliminar los campos vacíos comunes en registros manuales. Sin embargo, esto no descarta fallas técnicas del sensor (pérdida de señal o artefactos durante la lectura).

5.2. Procesamiento de Datos

A pesar de la ausencia de nulos tradicionales, se realizó una auditoría de calidad de datos que reveló dos hallazgos metodológicos:

Se reportan 562 registros idénticos (duplicados). En la metodología original de recolección de datos mediante sensores IoT en tiempo real (Mojumdar et al., 2025), la alta discretización de las constantes fisiológicas y la ausencia de un identificador único por paciente justifican la presencia de perfiles idénticos observados en distintas consultas. Por tanto, se decide conservar la totalidad de los 1014 registros para reflejar la densidad observacional del sistema de triaje rural, evitando sesgos por eliminación arbitraria.

Cuadro 3: Registros identificados con anomalías de hardware en el sensor de pulso

Índice	Age	SystolicBP	DiastolicBP	BS	BodyTemp	HeartRate	RiskLevel
499	16	120	75	7.9	98.0	**7**	low risk
908	16	120	75	7.9	98.0	**7**	low risk

Como se mencionó anteriormente, el valor mínimo de la frecuencia cardíaca es de 7 latidos por minuto. Dado que el resto de los signos vitales de esas dos filas (120/75 mmHg de presión y 98 °F de temperatura) son fisiológicamente coherentes, se decide conservar las filas e imputar el valor anómalo de la frecuencia cardíaca mediante la mediana del dataset (76 lpm).

5.3. Gráficas

Conforme a la información observada en los gráficos, no hay un desbalanceo extremo entre clases. Las distribuciones no son completamente normales pero sí observan una tendencia unimodal. Al tratarse de variables médicas existen límites fisiológicos inferiores pero colas superiores extendidas en casos severos:

1. Temperatura: Se observa la concentración masiva en 98 °F, donde casi 800 registros están estancados en ese valor debido al redondeo del sensor IoT, aportando baja varianza al modelo.

2. Presión Sistólica: Hay un pico notable en 120 mmHg. Esto ocurre porque los tensiómetros digitales tienden a redondear las mediciones a valores estándar normales.

3. BS (Glucosa): Muestra un sesgo hacia la derecha; la mayoría de las pacientes están entre 6 y 8 mmol/L, con una cola larga de casos críticos que se extiende hasta 19 mmol/L.

4. Frecuencia Cardíaca: Se concentra fuertemente entre 60 y 85 lpm.

5. Variable Target: Existen 406 casos de `low risk`, 336 de `mid risk` y 272 de `high risk`, lo que muestra un buen balance de clases para la discriminación Bayesiana.

Dicho esto, se debe tener en cuenta que la presencia de registros repetidos debido a la discretización requiere cautela al realizar la evaluación predictiva para evitar memorización de patrones exactos en conjuntos de validación.

5.4. Matriz de correlación

Al analizar el mapa de calor, se obtienen las siguientes conclusiones:

1. La correlación entre glucosa (BS) y el nivel de riesgo codificado es de 0.57, la más alta observada, indicando una fuerte relación positiva con el riesgo materno.

2. Presión Arterial (SystolicBP y DiastolicBP): Muestran una correlación con el riesgo de 0.40 y 0.35 respectivamente, evidenciando un impacto directo positivo alineado con el diagnóstico de trastornos hipertensivos. Presentan multicolinealidad entre sí ($r = 0{,}79$), lo que justifica regularizar sus efectos en la estructura prior.

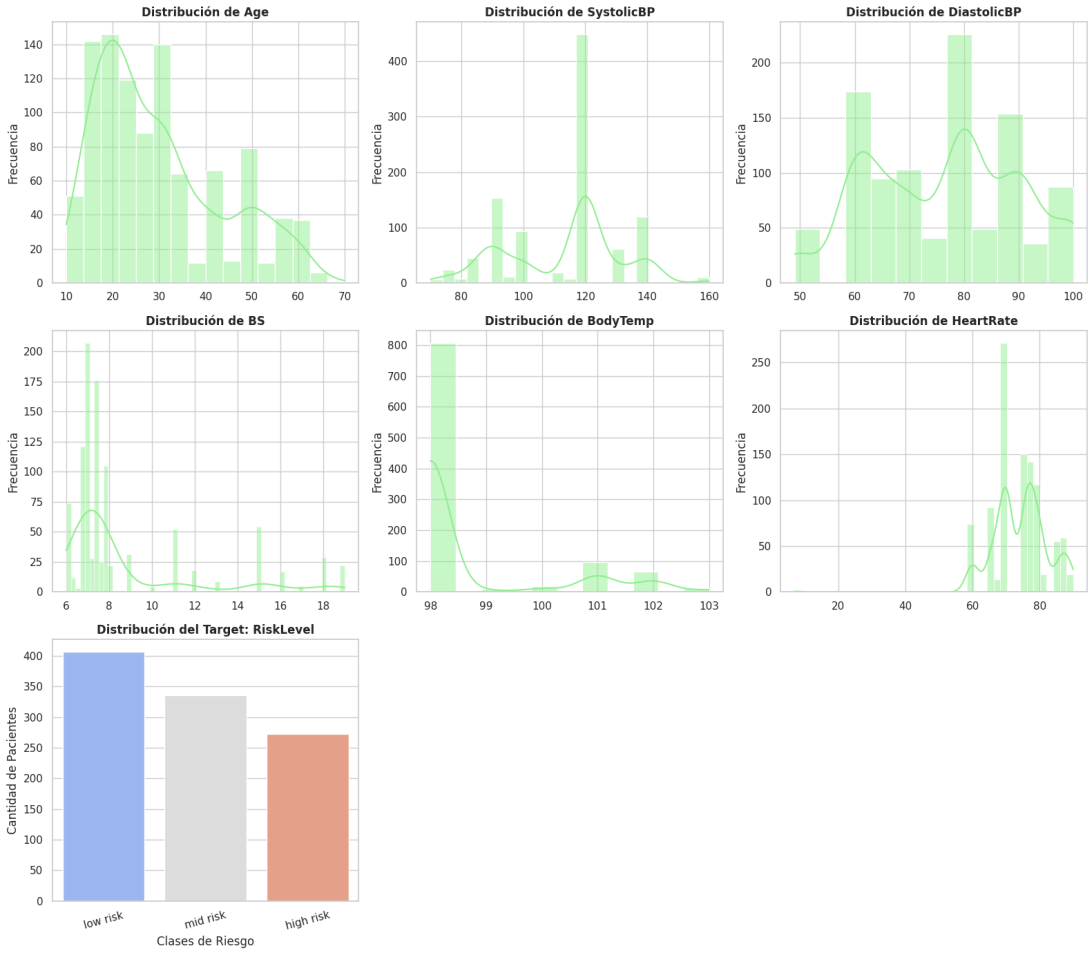


Figura 1: Distribución de frecuencias y curvas de densidad para las variables fisiológicas de entrada (Age, SystolicBP, DiastolicBP, BS, BodyTemp, HeartRate) y distribución de clases balanceadas del parámetro objetivo (RiskLevel).

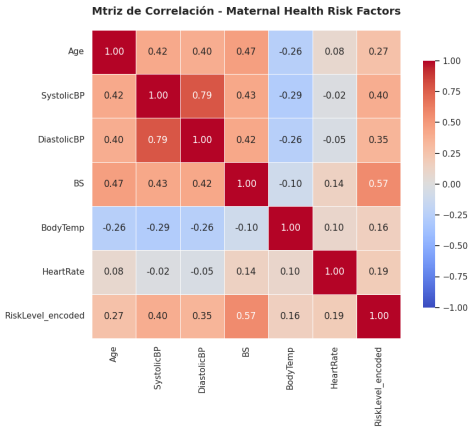


Figura 2: Matriz de correlación de Pearson entre las variables fisiológicas.

3. Temperatura corporal ($r = 0{,}16$) y frecuencia cardíaca ($r = 0{,}19$) presentan correlaciones moderadas-bajas debido a su menor varianza poblacional en la muestra.

6. Especificación del Modelo Ordinal e Identificación de Priors

6.1. Formulación del Modelo y Verosimilitud

Para conservar la estructura jerárquica natural del indicador de riesgo obstétrico $Y_i \in \{1 : \text{low risk}, 2 : \text{mid risk}, 3 : \text{high risk}\}$, se especifica un modelo de **Regresión Logística Ordinal** bajo la asunción de Odds Proporcionales.

Se definen las probabilidades acumuladas $P(Y_i \leq k \mid \mathbf{X}_i)$ para cada nivel $k \in \{1, 2\}$, donde la fun-

ción de enlace logit viene dada por:

$$\text{logit}(P(Y_i \le k \mid \mathbf{X}_i)) = \ln\left(\frac{P(Y_i \le k)}{1 - P(Y_i \le k)}\right) = \alpha_k - \eta_i \tag{1}$$

El predictor lineal η_i se construye sobre las 6 variables fisiológicas reales observadas en el dataset:

$$\eta_i = \beta_{\text{Age}} \cdot \text{Age}_i + \beta_{\text{Sys}} \cdot \text{SystolicBP}_i + \beta_{\text{Dia}} \cdot \text{DiastolicBP}_i + \beta_{\text{BS}} \cdot \text{BS}_i + \beta_{\text{Temp}} \cdot \text{BodyTemp}_i + \beta_{\text{HR}} \cdot \text{HeartRate}_i \tag{2}$$

donde $\alpha_1 < \alpha_2$ son los umbrales o puntos de corte (*cutpoints*) que delimitan las transiciones entre niveles de riesgo. A partir de las probabilidades acumuladas, las probabilidades categóricas individuales para cada paciente i se expresan como:

$$P(Y_i = 1) = P(Y_i \le 1) = \frac{1}{1 + e^{-(\alpha_1 - \eta_i)}} \tag{3}$$

$$P(Y_i = 2) = P(Y_i \le 2) - P(Y_i \le 1) = \frac{1}{1 + e^{-(\alpha_2 - \eta_i)}} - \frac{1}{1 + e^{-(\alpha_1 - \eta_i)}} \tag{4}$$

$$P(Y_i = 3) = 1 - P(Y_i \le 2) = 1 - \frac{1}{1 + e^{-(\alpha_2 - \eta_i)}} \tag{5}$$

La función de verosimilitud conjunta para la cohorte de $N = 1014$ gestantes sigue una distribución Categorical/Multinomial:

$$\mathcal{L}(\boldsymbol{\alpha}, \boldsymbol{\beta} \mid \mathbf{Y}, \mathbf{X}) = \prod_{i=1}^{1014} \prod_{k=1}^{3} [P(Y_i = k \mid \mathbf{X}_i)]^{I(Y_i = k)} \tag{6}$$

6.2. Priores para los Umbrales (α_1, α_2)

Los umbrales α_1 y α_2 determinan las proporciones base poblacionales en ausencia de covariables. Con base en la distribución empírica de la muestra en Bangladesh (406 low risk, 336 mid risk y 272 high risk sobre $N = 1014$):

- Proporción acumulada en $k = 1$: $406/1014 \approx 0{,}400 \implies \alpha_1 = \text{logit}(0{,}400) \approx -0{,}405$.
- Proporción acumulada en $k = 2$: $(406+336)/1014 \approx 0{,}732 \implies \alpha_2 = \text{logit}(0{,}732) \approx +1{,}005$.

Se fijan priores gaussianas informativas con restricción de ordenamiento ($\alpha_1 < \alpha_2$):

$$\alpha_1 \sim \mathcal{N}(\mu = -0{,}40, \sigma^2 = 0{,}50^2), \quad \alpha_2 \sim \mathcal{N}(\mu = 1{,}00, \sigma^2 = 0{,}50^2) \tag{7}$$

6.3. Presión Arterial (β_{Sys} y β_{Dia})

En el modelo logístico ordinal, el coeficiente β_j representa el incremento en el log-odds de alcanzar un nivel de riesgo superior por cada unidad de la variable.

Siguiendo las guías hemodinámicas de Saudan et al. (1998) y ACOG (citados en Nogholi et al., 2026), por cada aumento de 10 mmHg en la presión sistólica, los odds de severidad aumentan en un factor de 1,45 ($\beta_{\text{Sys}} = \frac{\ln(1{,}45)}{10} \approx 0{,}037$ mmHg^{-1}). Se especifica una prior Normal truncada positiva:

$$\beta_{\text{Sys}} \sim \mathcal{N}^{+}(\mu = 0{,}04, \sigma^2 = 0{,}02^2) \tag{8}$$

Para la presión diastólica, un incremento de 10 mmHg eleva los odds en OR $\approx 1{,}35$ ($\beta_{\text{Dia}} \approx 0{,}03$ mmHg^{-1}):

$$\beta_{\text{Dia}} \sim \mathcal{N}^{+}(\mu = 0{,}03, \sigma^2 = 0{,}02^2) \tag{9}$$

Esta formulación modera el efecto de la multicolinealidad observada ($r = 0{,}79$).

6.4. Glucemia / Diabetes (β_{BS})

Para la glucemia medida en mmol/L, el estudio de Mojumdar et al. (2025) reporta una fuerte asociación entre la hiperglucemia y el riesgo obstétrico. Un incremento de 1 mmol/L incrementa los odds acumulados de mayor riesgo en aproximadamente un 35 % (OR $\approx 1{,}35 \implies \beta_{\text{BS}} \approx 0{,}30$). Se asigna:

$$\beta_{\text{BS}} \sim \mathcal{N}^{+}(\mu = 0{,}30, \sigma^2 = 0{,}15^2) \tag{10}$$

6.5. Edad Materna (β_{Age})

De acuerdo con Haram et al. (2009) y Muglia et al. (2022), un incremento de 10 años en la edad materna eleva los odds acumulados de complicación en OR $\approx 1{,}35$ ($\beta \approx 0{,}03$ año^{-1}):

$$\beta_{\text{Age}} \sim \mathcal{N}(\mu = 0{,}03, \sigma^2 = 0{,}02^2) \tag{11}$$

6.6. Constantes Vitales Secundarias (β_{Temp} y β_{HR})

Para la temperatura corporal y frecuencia cardíaca, dada su baja varianza por la discretización de los sensores IoT, se especifican priores débilmente informativas / regularizadoras tipo Ridge centradas en cero (Gelman et al., 2014):

$$\beta_{\text{Temp}} \sim \mathcal{N}(\mu = 0{,}00, \sigma^2 = 0{,}50^2), \quad \beta_{\text{HR}} \sim \mathcal{N}(\mu = 0{,}00, \sigma^2 = 0{,}50^2) \tag{12}$$

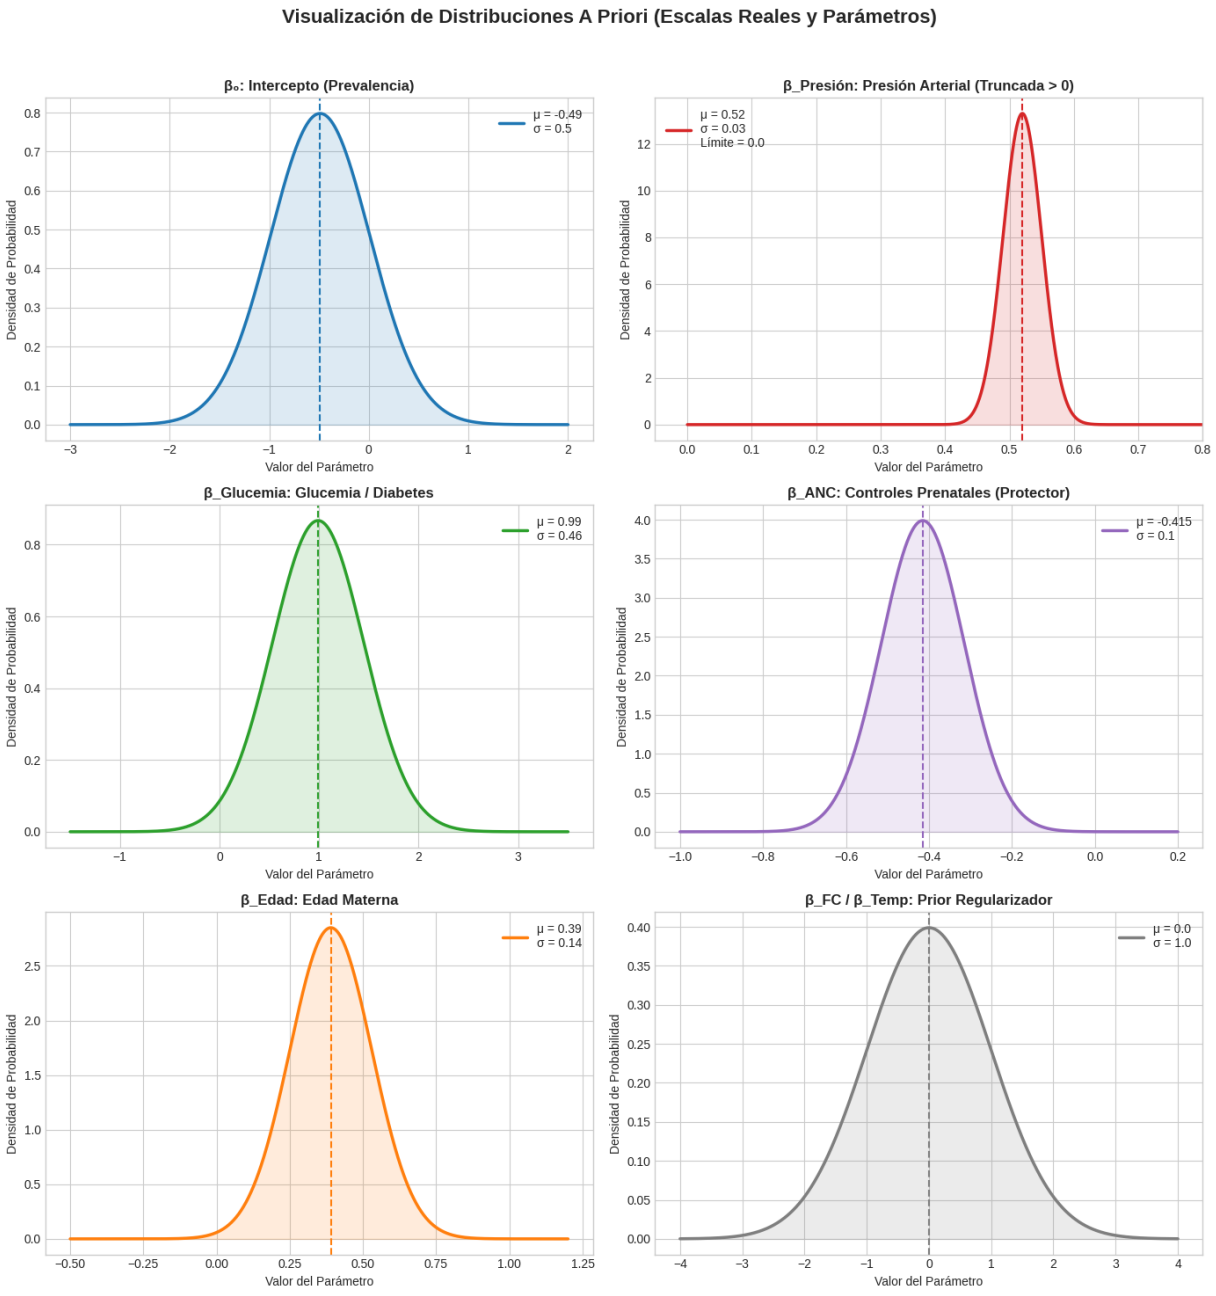


Figura 3: Distribuciones a priori especificadas para los parámetros del modelo Bayesiano.

Referencias

[1] Gelman, A., Carlin, J. B., Stern, H. S., Dunson, D. B., Vehtari, A., & Rubin, D. B. (2014). *Bayesian Data Analysis* (3rd ed.). CRC Press.

[2] Haram, K., Svendsen, E., & Abildgaard, U. (2009). The HELLP syndrome: Clinical issues and management. A review. *BMC Pregnancy and Childbirth*, 9, Artículo 8, 1–15. https://doi.org/10.1186/1471-2393-9-8

[3] Mojumdar, M. U., Sarker, D., Assaduzzaman, M., Shifa, H. A., Sajeeb, M. A. H., Islam, O., Bari, M. S., Alam, M. J., & Chakraborty, N. R. (2025). Maternal health risk factors dataset: Clinical parameters and insights from rural Bangladesh. *Data in Brief*, 59, Artículo 111363, 1–11. https://doi.org/10.1016/j.dib.2025.111363

[4] Mousavi Nogholi, M., Mozdgir, A., & Javid, Y. (2026). High-risk pregnancy prediction using Taguchi-optimized machine learning methods and TOPSIS-based model selection. *Scientific Reports*, 16, Artículo 23966, 1–23. https://doi.org/10.1038/s41598-026-55011-z

[5] Saudan, P., Brown, M. A., Buddle, M. L., & Jones, M. (1998). Does gestational hypertension become pre-eclampsia? *British Journal of Obstetrics and Gynaecology*, 105(11), 1177–1184. https://doi.org/10.1111/j.1471-0528.1998.tb09971.x

[6] Wondemagegn, A. T., Alebel, A., Tesema, C., & Abie, W. (2018). The effect of antenatal care follow-up on neonatal health outcomes: a systematic review and meta-analysis. *Public Health Reviews*, 39(1), Artículo 33, 1–11. https://doi.org/10.1186/s40985-018-0110-y