¿En qué medida las variables fisiológicas registradas permiten clasificar con precisión el nivel de riesgo de una gestante, y cuáles de estos factores tienen mayor peso predictivo?

Integrantes:

Sara Gabriela Chisaba Cárdenas
Alejandra Cortes Murillo
Juan Esteban Silva Arévalo

Curso:
Estadística Bayesiana

Universidad Externado de Colombia
Año 2026

1. Planteamiento del problema

1.1. Contexto

La reducción de la mortalidad materna y fetal, junto con tratamientos oportunos durante el embarazo son factores prioritarios a nivel de sanidad pública global lo cual se alinea con los ODS, como se menciona en (Organization, s.f.)“ Meta 3.1 de los ODS:Reducir la tasa mundial de mortalidad materna a menos de 70 por cada 100 000 nacidos vivos... Un poco más del 90 % de todas las muertes maternas ocurren en países de ingresos y medios bajos en 2023”. Por eso el principal problema radica en situaciones de monitorización primaria en zonas rurales o vulnerables de un país en desarrollo junto con la identificación temprana de los síntomas y/o complicaciones para descubrir el nivel de riesgo en función del seguimiento continuo de signos vitales como la frecuencia cardíaca presión arterial sistólica, temperatura corporal, etc. Sin embargo, evaluaciones puntuales o un control inconsistente dificultan la detección a tiempo de condiciones médicas críticas como la preeclampsia, diabetes gestacional, anemia ferropénica o hipertensión arterial, y según (Organization, s.f.) “La mayoría de las muertes maternas son prevenibles, ya que existen soluciones sanitarias bien conocidas para prevenir o controlar las complicaciones.”

No obstante, se depende demasiado del presupuesto público y gubernamentales para el financiamiento de proyectos de tecnologías o nuevas infraestructuras en la salud pública, mismo lo menciona (Ramos Vázquez, 2019) “La mayoría de muertes, lesiones y problemas de salud se pueden evitar mejorando el acceso a servicios adecuados de atención de la salud, incluidos los métodos de planificación familiar eficaces y la atención obstétrica de emergencia, reconociendo el derecho de la mujer y del hombre a la información y al acceso a métodos seguros, eficaces y asequibles...”. Bajo esta perspectiva y considerando que las complicaciones no detectadas a tiempo generan hospitalizaciones obstétricas, representando un costo significativamente mayor para el sistema de salud y las familias.

Asimismo, existen grandes diferencias respecto a la atención medica prenatal ofrecida o disponible en los distintos centros de atención rurales, alejados de las ciudades donde hay una brecha sea tecnológica o económica que dificultan el debido proceso de monitorización durante el embarazo. Por otro lado, el difícil acceso a recursos, bienes y servicio como lo es el agua potable y el sistema de saneamiento básico en ciertas comunidades vulnerables puede incrementar la susceptibilidad a infecciones durante la gestación y en consecuencia enfermedades.

Dicho esto y en síntesis de los anterior el cumplimiento estricto de las regulaciones sobre privacidad y confidencialidad de la información médica de los pacientes es fundamental al igual que las exigencias reglamentarias para la validación y certificación de modelos de Inteligencia Artificial y/o Estadística aplicados a la salud humana, dado a los tipos de datos a tratar, en este caso, son datos recopilados de diferentes hospitales, centros médicos de salud materna y clínicas comunitarias de las rurales de Bangladesh mediante un sistema de monitoreo de riesgos basado en IoT, con 1013 registros de pacientes con variaciones simultaneas en distintos indicadores fisiológicos, lo que demanda procesos de identificación de factores de riesgo para la adecuada intervención médica.

1.1.1. Fenómeno

En el proceso de parto, algunas mujeres sufren graves consecuencias, llegando incluso a la muerte. En algunos casos, se detecta en los últimos meses de embarazo enfermedades que podrían en riesgo a la madre gestante o al bebé.

- Síntomas
- Abortos espontáneos.
- Madres gestantes con hipertensión.
- Pareja de la madre gestante teniendo que decidir entre la vida de ella y su bebé.
- Partos complicados o sin éxito.
- Desigualdad social entre la zona urbana y la rural, en cuanto a la natalidad. Cerca del 43 % vive en zonas urbanas, impulsada por el crecimiento de su capital, Daca.
- Madres o bebés en UCI después del parto.
- Afectaciones psicológicas de las madres posterior al parto.
- Bajas tasas de natalidad. En 1990 la tasa era de 32.8 y para 2022 la misma tasa fue de 19.8.

1.1.2. Problema

No se ha profundizado lo suficiente en la evaluación de la suficiencia de los datos clínicos de rutina para la detección oportuna de riesgos durante el embarazo en entornos con recursos limitados. Aunque la literatura indica que la información clínica de los controles prenatales posee un valor predictivo mayor respecto a los datos demográficos, la necesidad de determinar qué tan viable y preciso resulta implementar estos modelos predictivos cuando se trabaja bajo la restricción de muestras pequeñas y la escasez de personal u equipo médico aún se evidencia.

2. Pregunta de investigación

¿En qué medida las variables fisiológicas registradas (presión arterial, glucosa, temperatura corporal, frecuencia cardíaca y edad) permiten clasificar con precisión el nivel de riesgo (RiskLevel) de una gestante, y cuáles de estos factores tienen mayor peso predictivo?

3. Justificación

1. Resultados esperados y riesgos proyectados:

El proyecto nos ofrecerá un sistema predictivo de triaje prenatal adaptado a entornos de atención primaria en comunidades rurales de escasos recursos. Con una de las bases, las sugerencias de optimización de hiperparametros y selección de modelos (Nogholi, Shafiabadi, Khosravi, Deldar, High-risk pregnancy prediction using Taguchi-optimized machine learning methods and TOPSIS-based model selection, 2026), se espera construir un modelo computacionalmente eficaz y de alto rendimiento que priorice la sensibilidad o recall, garantizando la detección oportuna de gestantes en estado crítico antes del parto. Este resultado permitirá aclarar la toma de decisiones clínicas y optimizar la asignación de recursos públicos en zonas rurales, esperando de manera más generalizada, orientando el transporte medico como ambulancias y la remisión a centros hospitalarios únicamente a los casos que representan un verdadero alto riesgo y no una falsa alarma (Nogholi, Shafiabadi, Khosravi, Deldar, High-risk pregnancy prediction using Taguchi-optimized machine learning methods and TOPSIS-based model selection, 2026)

Por otro lado, Los principales riesgos del proyecto serian el sobreajuste o la pérdida de precisión al transferir el modelo a otras regiones desatendidas y/o contexto (Nogholi, Shafiabadi, Khosravi, Deldar, High-risk pregnancy prediction using Taguchi-optimized machine learning methods and TOPSIS-based model selection, 2026), la presencia de ruido o fallas en la captura de características fisiológicas de las madres gestantes mediante sensores IoT , y al ser modelos los cuales dan el resultado, son muy opacos, dan el resultado pero no una explicación medica al respecto, generando una falta de explicación clínica, desconfianza de personal médico, al no comprender de donde sale la toma de decisiones del modelo, al no integrar mecanismos de Inteligencia Artificial Explicable (XAI), existe el peligro de que la herramienta sea ignorada en la práctica real o rechazada (Nogholi, Shafiabadi, Khosravi, Deldar, High-risk pregnancy prediction using Taguchi-optimized machine learning methods and TOPSIS-based model selection, 2026).

3.1. Mapa de Actores

El desarrollo de un modelo predictivo de riesgo materno-perinatal trasciende la precisión técnica; su éxito depende de equilibrar las exigencias clínicas, regulatorias y operativas de todo el mapa de actores.

1. **Decisores:**
   - Directores médicos.
   - Jefes de obstetricia.
   - Instituciones prestadoras de servicios de Salud (directores financieros y de protección de datos).
   - Comités de ética.
2. **Usuarios:**
   - Médicos generales.
   - Ginecobstetras.
   - Enfermeros.
3. **Afectados:**
   - Madres gestantes.
   - Bebés.
   - Familiares.
   - Médicos.
4. **Responsables:**
   - Encargados del proyecto.

- Equipo de Ciencia de Datos.
- Capacitadores.

Además de estos en específico, las mujeres se desempeñan en varios ámbitos, por lo que situaciones que la pongan en riesgo influyen también en sus empleadores, en sus círculos sociales, personas de su entorno laboral, colectivos sociales, entre otros.

4. Objetivos

Desarrollar un modelo de clasificación que, a partir de las variables fisiológicas registradas (presión arterial sistólica y diastólica, glucosa, temperatura corporal, frecuencia cardíaca y edad), permita predecir con precisión el nivel de riesgo (RiskLevel) de una gestante, identificando los factores con mayor peso predictivo para facilitar la intervención médica oportuna.

4.1. Objetivos específicos

1. Describir el comportamiento y distribución de las variables fisiológicas según el nivel de riesgo.
2. Identificar los factores fisiológicos más asociados con un riesgo alto.
3. Construir y comparar modelos que permitan clasificar el nivel de riesgo con mayor precisión.
4. Proponer criterios para priorizar la atención médica según el nivel de riesgo detectado.

5. Análisis Exploratorio

Se parte de una base de datos, recolectada a partir de un sistema de sensores IoT, para desarrollar un mecanismo de monitoreo efectivo y de predicción del nivel de riesgo que puede tener una madre gestante, en el contextos de zonas rurales o vulnerables de una ciudad en desarrollo, en este caso en Bangladesh, donde se analizarán los datos de salud, variables fisiológicas y nivel de riesgo, con el fin de reducir la tasa de mortalidad materna e infantil. La base de datos queda cargada, cuenta con 6 variables con 1013 registros de madres gestantes, pacientes de diferentes hospitales, clinicas comunitarias y centros de atención materna enzonas rurales de Bangladesh.

5.1. Análisis Descriptivo

La base de datos cuenta con 6 variables con 1013 registros de madres gestantes, pacientes de diferentes hospitales, clinicas comunitarias y centros de atención materna enzonas rurales de Bangladesh. Se procedió a evaluar el comportamiento individual de las variables fisiológicas de las 1,013 gestantes. Mediante un análisis estadístico descriptivo.

Cuadro 1: Estadísticas descriptivas de las variables fisiológicas del dataset ($N = 1014$)

	Age	SystolicBP	DiastolicBP	BS	BodyTemp	HeartRate
count	1014.00	1014.00	1014.00	1014.00	1014.00	1014.00
mean	29.87	113.20	76.46	8.73	98.67	74.30
std	13.47	18.40	13.89	3.29	1.37	8.09
min	10.00	70.00	49.00	6.00	98.00	7.00
25 %	19.00	100.00	65.00	6.90	98.00	70.00
50 %	26.00	120.00	80.00	7.50	98.00	76.00
75 %	39.00	120.00	90.00	8.00	98.00	80.00
max	70.00	160.00	100.00	19.00	103.00	90.00

Con la información observada en la información estadística del dataset, se concluye:

1. El valor mínimo de la frecuencia cardíaca es de 7.000000 latidos por minuto, lo cual es biológicamente imposible, lo que demuestra que pese a las pruebas antes realizadas por nulos existe esta evidencia de fallos al momento de registrar en el sistema estos resultados, con un valor cercano a cero en vez de un nulo oficial. Por lo que se toma acción para evitar errores en el entrenamiento del algoritmo futuro.
2. Respecto a lo reflejado en la glucosa de la sangre: La media respecto al rango normal si está alta, no muestra un nivel saludable estándar, sin embargo, se ve que un paciente tiene 19 mmol/L de glucosa en sangre lo que puede indicar que está sufriendo por hiperglucemia severa, y al compararlo con e 75 % de los datos que están por debajo del 8.0, ese valor tan alto en máx confirma que la distribución tiene un sesgo positivo, causado por pacientes con riesgo crítico.
3. Presión Arterial, diastólica y sistólica: La presión sistólica varía desde un mínimo de 70 hasta un máximo de 160, la diastólica llega hasta 100, y teniendo en cuenta el contexto de la salud materna, una presión de 160/100 mmHg es una alarma inmediata que usualmente indica preeclampsia o hipertensión gestacional severa. De igual manera, la desviación estándar de la sistólica es de 18.4, lo que muestra una dispersión muy alta de

los datos; sugiriendo que las pacientes están repartidas entre rangos muy saludables y rangos de emergencia médica.

4. Temperatura Corporal: La desviaciónestándar es extremadamente baja, de solo 1.37. El 25 %, el 50 % y el 75 % de los datos valen exactamente lo mismo: 98.000000 °F que son aproximadamente unos 36.6 °C, lo que puede ser causa del termómetro digital utilizado en el sistema IoT, que puede estar configurado con muy poca sensibilidad o redondea mucho los datos. Casi toda la muestra de 1013 mujeres está estancada exactamente en 98 °F, y solo unas pocas llegaron al máximo de 103 °F. Por eso el sd es muy bajo, debido al poco cambio que hay aportando muy poca información para el modelo.

5. Edad: Respecto a está variable, aunque el 75 % de las mujeres tienen 39 años o menos que es la edad fertil, tener un registro de una paciente de 10 años y otra de 70 años en un estudio de salud materna, representa casos extremadamente atípicos que puede ser o embarazo infantil o geriatría extrema o errores de digitalización en el hospital al ingresar la edad.

Cuadro 2: Estructura de las variables y verificación de valores nulos ($N = 1014$)

Variable	Tipo de Dato	Registros No Nulos	Valores Nulos (NaN)
Age	Entero (`int64`)	1014	0
SystolicBP	Entero (`int64`)	1014	0
DiastolicBP	Entero (`int64`)	1014	0
BS	Flotante (`float64`)	1014	0
BodyTemp	Flotante (`float64`)	1014	0
HeartRate	Entero (`int64`)	1014	0
RiskLevel	Objeto (`object`)	1014	0

No se observan datos nulos en ninguna variable, al ser una base recolectada por un sistema de recolección de IoT que es el Internet de las Cosas, estos están diseñados para reducir de forma drástica o incluso eliminar por completo los datos nulos comunes en registros médicos llenados a mano, que son tan comunes cuando los humanos llenan registros médicos a mano. Sin embargo, el sistema no descarta por completo que no hayan nulos, pueden existir fallas tecnicas del sensor, como fallos de conexión, movimientos fuertes del paciente durante el registro, etc.

5.2. Procesamiento de Datos

A pesar de la ausencia de nulos tradicionales, se realizó una auditoría de calidad de datos que reveló dos hallazgos metodológicos:

Se reportan 562 duplicados. En el paper de referencia y dueño de la base de datos, se específica que la metodología de recolección de datos es mediante sensores IoT en tiempo real, como se menciona anteriormente, lo que puede explicar en gran medida que muchas medidas sean redondeadas y si a esto le sumamos que hay muy pocas variables y las filas no cuentan con identificador de registro específico, no se consideran datos duplicados, además en algunos casos está la misma información en signos vitales pero la clasificación de nivel de riesgo es diferente.

Cuadro 3: Registros identificados con anomalías de hardware en el sensor de pulso

Índice	Age	SystolicBP	DiastolicBP	BS	BodyTemp	HeartRate	RiskLevel
499	16	120	75	7.9	98.0	**7**	low risk
908	16	120	75	7.9	98.0	**7**	low risk

Como se menciono anteriormente el valor mínimo de la frecuencia cardíaca es de 7.000000 latidos por minuto y el resto de los signos vitales de esas dos filas como 120/75 de presión y 98°F de temperatura, son datos reales, limpios y valiosos,no se quiere eliminar toda la fila, perdiendo información importante sino reemplazar ese 7 de frecuencia cardíaca por la mediana del dataset.

5.3. Gráficas

Conforme a la información observada en los gráficos, no hay un desbalanceo tan evidente entre clases. La distribuciones no son completamente normales pero sí se observa una tendencia a ello. Sin embargo, al tratarse de variables médicas hay algunas con limites inferiores pero sin limites superiores muy estrictos, causando que las distribuciones tengan un sesgo natural a la derecha. Sustentando lo anterior:

1. Temperatura: Se observa la gigantesca barra en 98, y conforme a lo mencionado anteiormente casi 800 registros están estancados en ese valor debido al redondeo o la configuración del sensor IoT, tiene una varianza muy baja, por lo que aportará muy poco al modelo es la mayoría de los casos.

2. Presión Sistólica: Hay un pico notable en 120. Esto ocurre probablemente porque los tensiómetros digitales comerciales o los médicos tienden a redondear"las mediciones al valor estándar normal 120 mmHg en lugar de registrar fluctuaciones finas como 118 o 121.

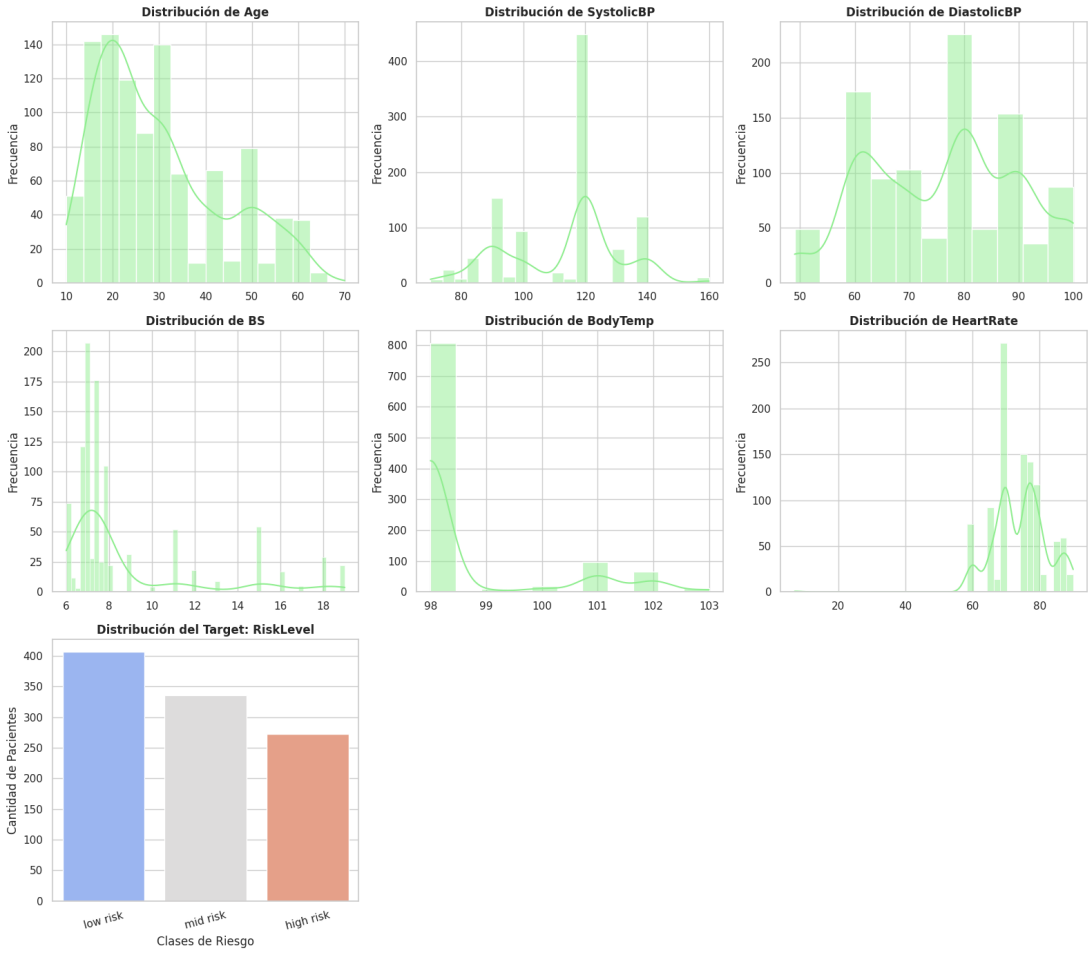


Figura 1: Distribución de frecuencias y curvas de densidad para las variables fisiológicas de entrada (Age, SystolicBP, DiastolicBP, BS, BodyTemp, HeartRate) y distribución de clases balanceadas del parámetro objetivo (RiskLevel).

3. BS la glucosa: Aquí se ve el sesgo hacia la derecha, antes mencionado ya que la mayoría de los pacientes está concentrada entre 6 y 8 mmol/L, pero hay una cola larga de casos críticos que se extiende hasta casi 19.

4. La frecuencia Cardíaca:Las frecuencias cardíacas reales se concentran fuertemente entre 60 y 85 lpm.

5. Respecto a la variable target hay aproximadamente 400 casos de low risk, unos 330 de mid risk y cerca de 270 de high risk, lo que muestra un buen balanceo entre las clases, demostrando que el modelo tiene suficientes ejemplos reales de cada nivel de riesgo para aprender a diferenciarlos entre si.

Dicho esto si se debe tener en cuenta que la presencia de picos tan masivos y exactos, combinados con el hecho de que hay más de 500 filas duplicadas porque son pacientes diferentes con idénticos signos vitales, en el caso de hacer una división aleatoria como train, test,split, el modelo puede memorizar estos patrones exactos en el set de entrenamiento y los evaluará con copias idénticas en el set de prueba, lo que puede causar sobreajuste engañoso.

5.4. Matriz de correlación

Al analizar el mapa de calor, se sacan las siguientes conclusiones:

1. La correlación entre BS y RiskLevel-encoded es de 0.57, que es la más alta evidenciada lo que indica una correlación positiva fuerte, lo que significa que a medida que los niveles de azúcar en sangre aumentan en la paciente, el nivel de riesgo de salud materna se eleva de forma muy marcada, puede ser un buen indicador de riesgo.

2. La Presión Arterial SystolicBP y DiastolicBP: La presión sistólica tiene una correlación de 0.40 con el riesgo, mientras que la diastólica

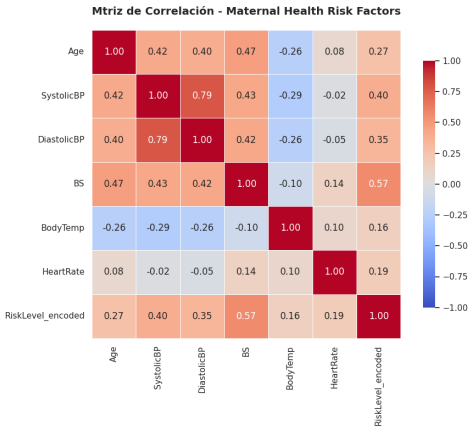


Figura 2: Matriz de correlación de Pearson entre las variables fisiológicas.

tiene 0.35, por lo que ambas variables tienen un impacto directo y positivo en el riesgo, en ptras palabras a mayor presión, mayor riesgo, lo cual se alinea perfectamente con el diagnóstico clínico de la preeclampsia. Tmabién muestran multicolinealidad ya que la correlación de SystolicBP y DiastolicBP es de 0.79, ambas presiones se mueven juntas, es algo a tener en cuenta al momento de realizar regresión logística ya que puede causar inestabilidad en los coeficientes.

3. La temperatura corporal tiene una correlación de 0.16 y la frecuencia cardíaca de 0.19 con el nivel de riesgo, pues como se mostro anteriormente en los histogramas, la temperatura estaba en su mayoría estancada en 98 °F con poca varianza evidenciada, por eso a no variar tanto entre pacientes sanas y enfermas, su correlación con el riesgo es muy baja, por lo que al momento de entrenar el modelo se les asignará menos importancia.

6. Especificación e Identificación de Priors

6.1. Prior Poblacional (Intercepto)

La constante o intercepto del modelo β_0 representa el log-odds a priori de que una gestante pertenezca a la clase de alto riesgo en ausencia de información sobre sus signos vitales. Tomando como referencia la prevalencia poblacional de riesgo en comunidades rurales del Sur de Asia documentada por Kuppusamy et al. (2023) (citado en Mousavi Nogholi et al., 2026) y la distribución del dataset clínico en Bangladesh de Mojumdar et al. (2025), donde aproximadamente el 38 % de la cohorte hospitalaria fue clasificada en alto riesgo, se especifica una priora informativa gaussiana centrada en $\mu = -0{,}49$. Esta especificación previene que el algoritmo asuma una distribución simétrica 50/50, ajustando la estimación inicial a la prevalencia real observada en sistemas de atención primaria.

6.2. Presión Arterial

Los trastornos hipertensivos del embarazo constituyen el indicador primario para la detección de preeclampsia y eclampsia. De acuerdo con Saudan et al. (1998), la hipertensión gestacional presenta una progresión directa hacia la preeclampsia severa. Asimismo, las guías de la American College of Obstetricians and Gynecologists (ACOG), resumidas en Mousavi Nogholi et al. (2026), reportan un Odds Ratio de 1.68 (IC 95 %: 1.59 – 1.78) para complicaciones maternas por hipertensión. Aplicando la conversión a log-odds, se define un prior normal positiva. El ajuste para números positivos garantiza el sentido del modelo, impidiendo que aumentos en la presión arterial reduzcan erróneamente la probabilidad de riesgo.

6.3. Glucemia / Diabetes

La descompensación glucémica y la diabetes preexistente se asocian de forma crítica con desenlaces gestacionales adversos. En la caracterización del dataset de Kurigram por Mojumdar et al. (2025), el 92.5 % de las pacientes con diabetes fueron categorizadas en riesgo alto (310 de 335 casos; $p = 4{,}85 \times 10^{-119}$). Asimismo, el meta-análisis de Zhang et al. (2025) (citado en Mousavi Nogholi et al., 2026) reporta un OR = 2,70 (IC 95 %: 1.10 – 6.60). Debido a que la etiqueta de riesgo en Mojumdar et al. carece de definición operativa explícita y podría introducir circularidad analítica, se asigna un prior suave con varianza ampliada ($\sigma = 0{,}46$). Esto le otorga al modelo libertad para ajustar la magnitud del efecto a partir de los datos empíricos de la cohorte sin verse dominado por el sesgo previo de etiquetado.

6.4. Controles Prenatales

El seguimiento sistemático del embarazo constituye la intervención primaria de salud pública para reducir la mortalidad perinatal. El meta-análisis global de Wondemagegn et al. (2018), realizado sobre 18 estudios observacionales ($N = 94{,}118$ nacimientos), demuestra que el seguimiento de atención prenatal (ANC) ejerce un efecto protector sig-

nificativo, reduciendo el riesgo en un 34 % a nivel global y un 41 % en regiones vulnerables (RR = 0,66, IC 95 %: 0.54 – 0.80). En la escala logarítmica ($\ln(0{,}66) = -0{,}415$). El signo negativo de la media refleja matemáticamente la disminución del riesgo a medida que se incrementa la adherencia a los controles clínicos.

6.5. Edad Materna

Las gestaciones en los extremos de la vida fértil (adolescencia y edad materna avanzada ≥ 35 años) conllevan una mayor susceptibilidad a descompensaciones vasculares y síndromes multisistémicos como el síndrome HELLP. De acuerdo con Haram et al. (2009) y el estudio poblacional de Muglia et al. (2022) (citado en Mousavi Nogholi et al., 2026), la edad materna avanzada incrementa el riesgo de complicación severa con un OR = 1,48 (IC 95 %: 1.12 – 1.96). Esta distribución asigna una ponderación positiva a la edad sobre datos estandarizados o transformados no linealmente.

6.6. Constantes Vitales Secundarias

Para las variables fisiológicas exploratorias (como la frecuencia cardíaca y la temperatura corporal), sobre las cuales no se dispone de un Log-Odds Ratio consolidado en meta-análisis previos, se adoptan priores débilmente informativos. Siguiendo los estándares de modelado Bayesiano de Gelman et al. (2014) y las recomendaciones de preprocesamiento de Mousavi Nogholi et al. (2026), se asigna una distribución gaussiana estándar sobre las variables previamente estandarizadas (Z-score). Esta distribución funciona equivalentemente a una regularización tipo Ridge (L_2), conteniendo coeficientes desproporcionados provocados por ruido en los sensores IoT de campo y permitiendo que la muestra real ($N = 1{,}013$) determine la significancia de estas variables.

Referencias

[1] Haram, K., Svendsen, E., & Abildgaard, U. (2009). The HELLP syndrome: Clinical issues and management. A review. *BMC Pregnancy and Childbirth*, 9, Artículo 8, 1–15. https://doi.org/10.1186/1471-2393-9-8

[2] Mojumdar, M. U., Sarker, D., Assaduzzaman, M., Shifa, H. A., Sajeeb, M. A. H., Islam, O., Bari, M. S., Alam, M. J., & Chakraborty, N. R. (2025). Maternal health risk factors dataset: Clinical parameters and insights from rural Bangladesh. *Data in Brief*, 59, Artículo 111363, 1–11. https://doi.org/10.1016/j.dib.2025.111363

[3] Mousavi Nogholi, M., Mozdgir, A., & Javid, Y. (2026). High-risk pregnancy prediction using Taguchi-optimized machine learning methods and TOPSIS-based model selection. *Scientific Reports*, 16, Artículo 23966, 1–23. https://doi.org/10.1038/s41598-026-55011-z

[4] Saudan, P., Brown, M. A., Buddle, M. L., & Jones, M. (1998). Does gestational hypertension become pre-eclampsia? *British Journal of Obstetrics and Gynaecology*, 105(11), 1177–1184. https://doi.org/10.1111/j.1471-0528.1998.tb09971.x

[5] Wondemagegn, A. T., Alebel, A., Tesema, C., & Abie, W. (2018). The effect of antenatal care follow-up on neonatal health outcomes: a systematic review and meta-analysis. *Public Health Reviews*, 39(1), Artículo 33, 1–11. https://doi.org/10.1186/s40985-018-0110-y

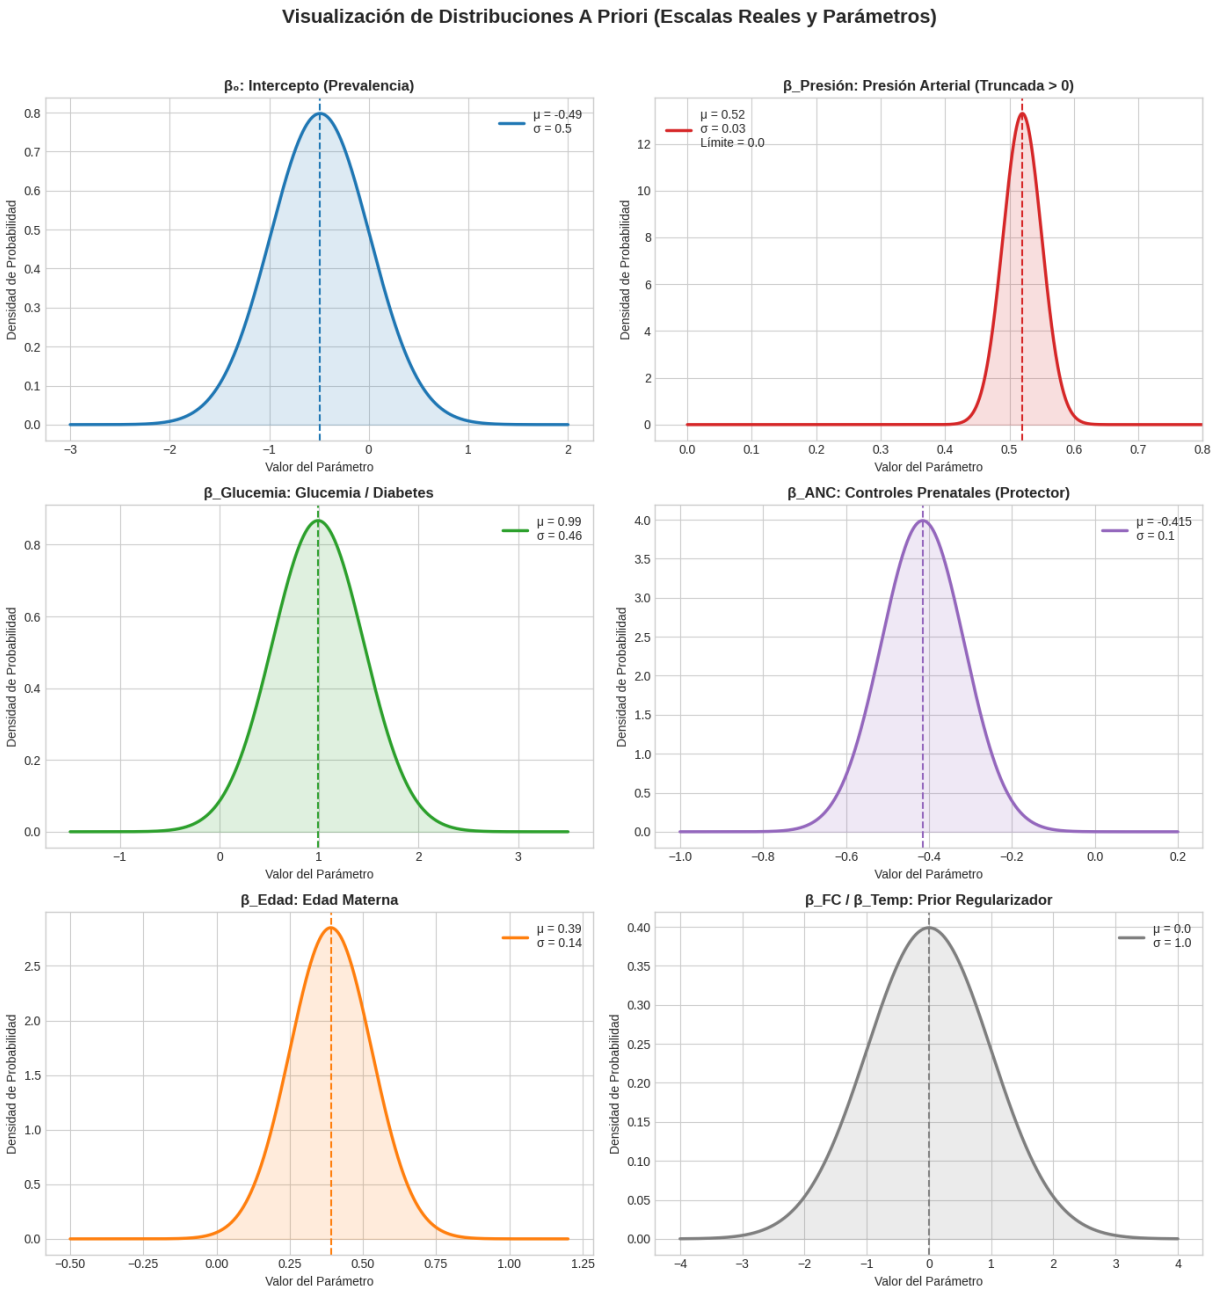


Figura 3: Distribuciones a priori especificadas para los parámetros del modelo Bayesiano.